UNIVERSIDAD TECNOLÓGICA NACIONAL
FACULTAD REGIONAL PARANÁ

Tesis de Maestría en Minería de Datos

Aumentación de datos mediante autoencoders variacionales y su impacto en estrategias de selección de características basadas en algoritmos genéticos

Claudio Sebastian Castillo

Director: Dr. Matías Gerard · Codirector: Dr. Leandro Vignolo

Universidad Tecnológica Nacional, Facultad Regional Paraná · 2026

Organización

1 Introducción
motivación, selección de características, estado del arte, propuesta y objetivos

2 Marco teórico
autocodificadores variacionales, algoritmos genéticos, métricas

3 Materiales y métodos
conjuntos de datos, línea base, modelos, diseño experimental

4 Resultados
calidad de los datos sintéticos, resultados globales, análisis por conjunto

5 Conclusiones y trabajos futuros
conclusiones, limitaciones, trabajos futuros

La maldición de la dimensionalidad: conjuntos con miles de variables y decenas de observaciones

Microarreglos de ADN

Miles de genes medidos sobre decenas de pacientes.

Video, finanzas, redes sociales

Problemas representados por grandes conjuntos de variables.

Maldición de la dimensionalidad	Alta demanda computacional y costo de optimización en espacios de muchas variables, que vuelven intratables ciertos problemas en la práctica (Bolón-Canedo et al., 2015).
Selección de características	Detectar las variables relevantes y descartar las irrelevantes o redundantes, con mínima pérdida de rendimiento.

Cuatro propiedades de los datos dificultan la selección de características

Alta dimensionalidad y escasez muestral

Muchas más variables que observaciones: sobreajuste, o modelos que no capturan la estructura de los datos.

Desbalance de clases

La evaluación prioriza la clase mayoritaria y descarta variables útiles para las minoritarias.

Complejidad

Ambigüedad de clases, fronteras de decisión complejas y dispersión de las muestras.

Ruido

Variables sin poder predictivo mezcladas con las relevantes.

Estos cuatro problemas organizan la tesis y la elección de los conjuntos de datos.

Los métodos envolventes capturan las interacciones entre variables, pero el espacio de 2^n subconjuntos es computacionalmente intratable

Filtro

- Preprocesamiento independiente del modelo.
- Rápido y escalable.
- No considera las interacciones entre variables.

Envolvente

- Evalúa cada subconjunto con un clasificador.
- Captura dependencias entre variables.
- Costo exponencial: 2^n subconjuntos posibles.

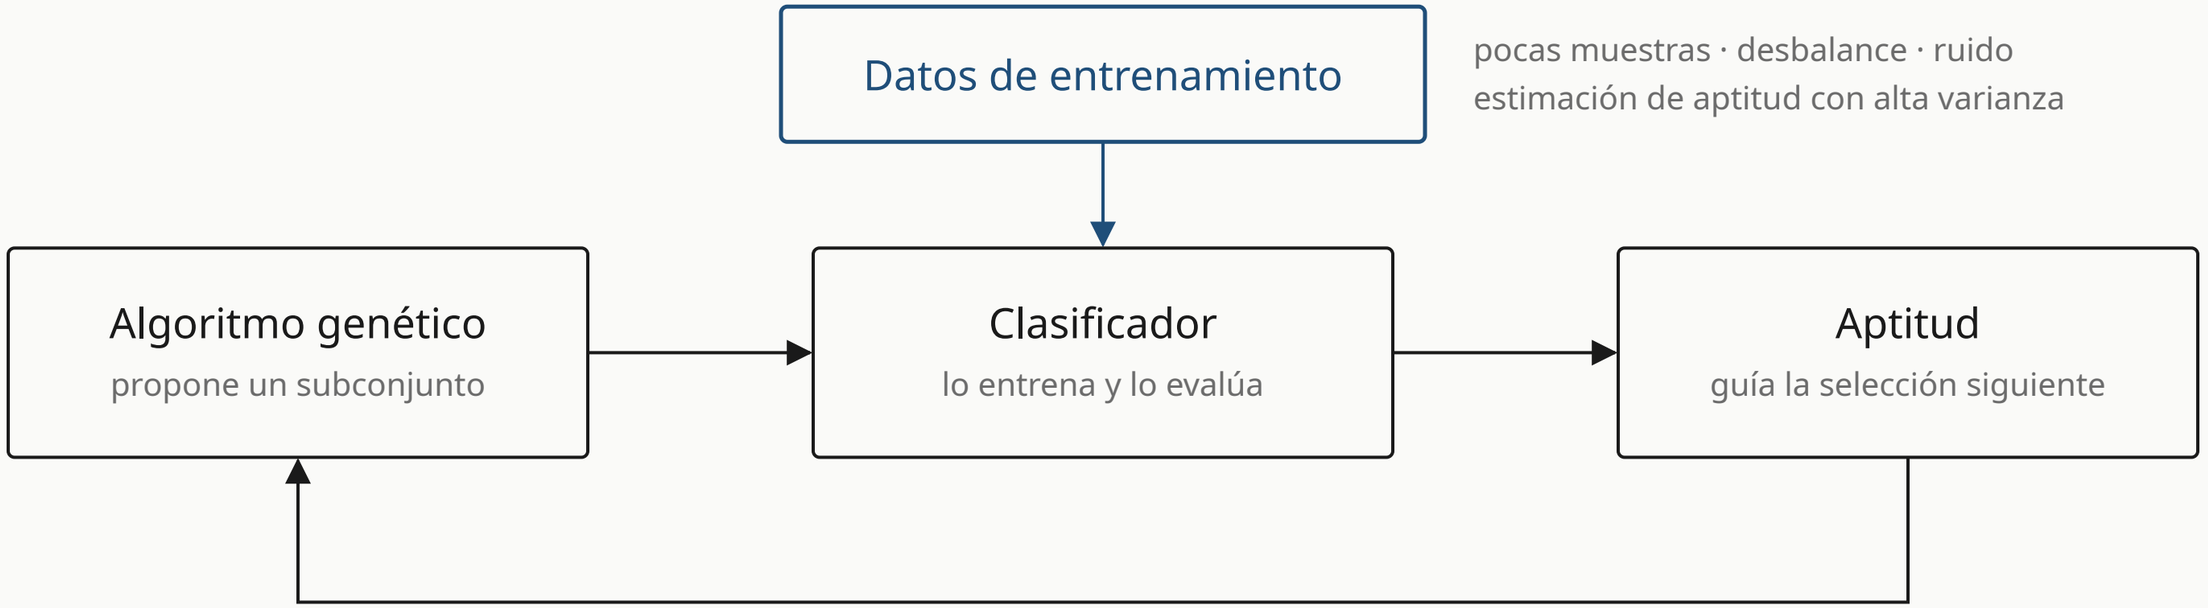
Embebido

- La selección ocurre durante el entrenamiento.
- Menor costo que el envolvente.
- Específico de cada modelo.

Con n = 16.063 genes, la búsqueda exhaustiva es intratable: se recurre a heurísticas de búsqueda.

Método envolvente + heurística de búsqueda = algoritmo genético (Vignolo et al., 2017).

En un algoritmo genético, la calidad de la estimación de aptitud está acotada por los datos disponibles



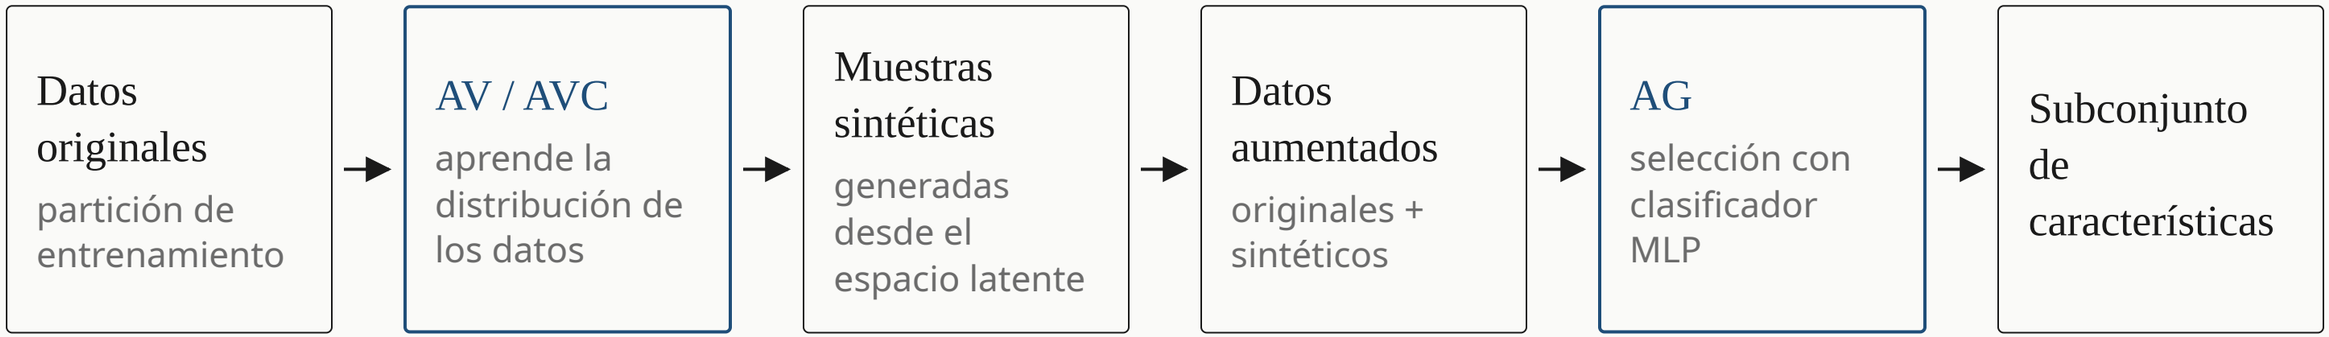
La escasez de datos no limita al algoritmo de búsqueda, sino a la estimación de aptitud que lo guía.

La aumentación de datos con modelos generativos es una respuesta reciente a la escasez muestral

Técnica	Mecanismo	Alcance en alta dimensionalidad con pocas muestras
SMOTE	Interpola entre vecinos cercanos; rebalancea clases.	La interpolación pierde sentido; no aporta beneficio (Blagus y Lusa, 2013).
Redes generativas antagónicas (GAN)	Un generador compite con un discriminador.	Entrenamiento inestable con pocas muestras (Fajardo et al., 2021).
Autocodificador variacional (AV)	Aprende una distribución latente continua de los datos.	Preserva la estructura estadística; mejor generador en comparaciones recientes (Fajardo et al., 2021; Ai et al., 2023).

Los AV se han aplicado a la generación de imágenes, texto, habla, datos tabulares, datos longitudinales y grafos.

Propuesta: generación de muestras sintéticas mediante AV y selección de características con AG sobre los datos aumentados



El AV se entrena únicamente con la partición de entrenamiento.

La exactitud se mide siempre en la partición original de testeo, sin datos sintéticos.

Objetivo general y objetivos específicos

Objetivo general

Evaluar el impacto de la aumentación de datos mediante AV sobre el desempeño de estrategias de selección de características basadas en AG.

Objetivos específicos

1. Integrar estrategias de aumentación basadas en AV en los AG.
2. Evaluar el desempeño de las estrategias propuestas en conjuntos de datos de diferente complejidad.
3. Comparar el AG con datos aumentados frente al mismo AG sin aumentación.

Hipótesis. Aumentar sintéticamente las muestras permite al AG identificar subconjuntos más relevantes, con mejor exactitud y eficiencia de selección.

Organización

1 Introducción
motivación, selección de características, estado del arte, propuesta y objetivos

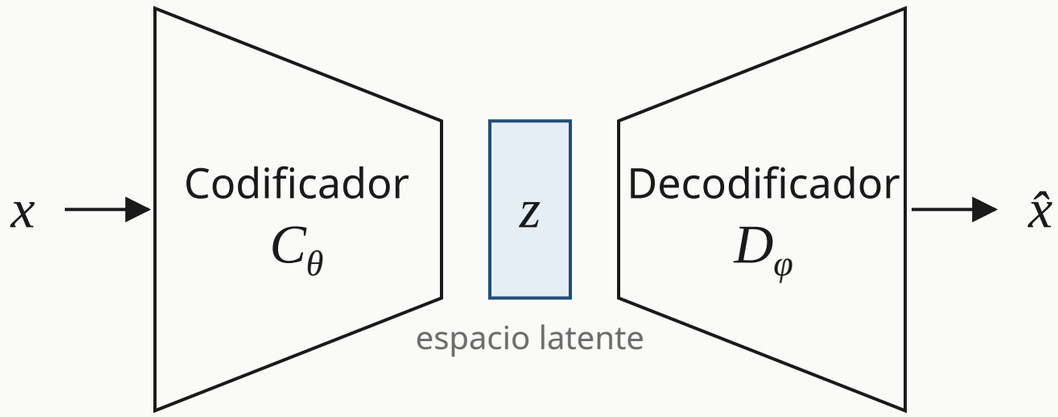
2 Marco teórico
autocodificadores variacionales, algoritmos genéticos, métricas

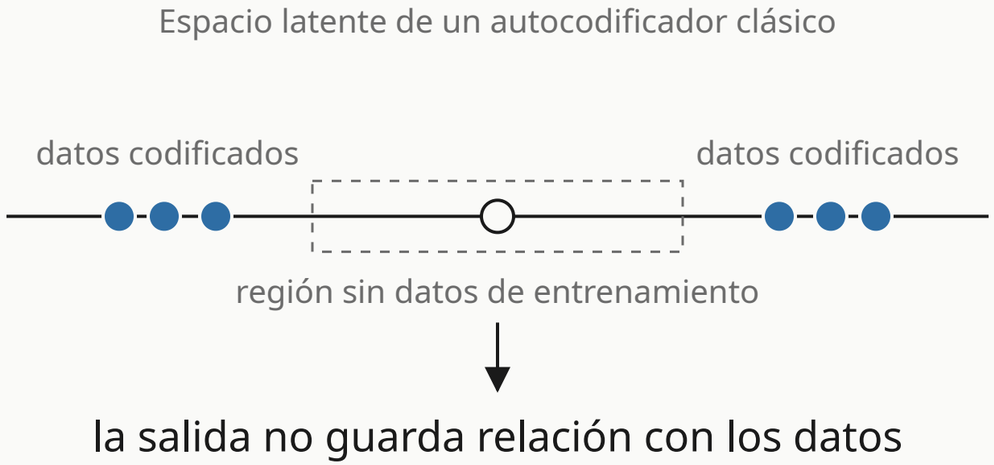
3 Materiales y métodos
conjuntos de datos, línea base, modelos, diseño experimental

4 Resultados
calidad de los datos sintéticos, resultados globales, análisis por conjunto

5 Conclusiones y trabajos futuros
conclusiones, limitaciones, trabajos futuros

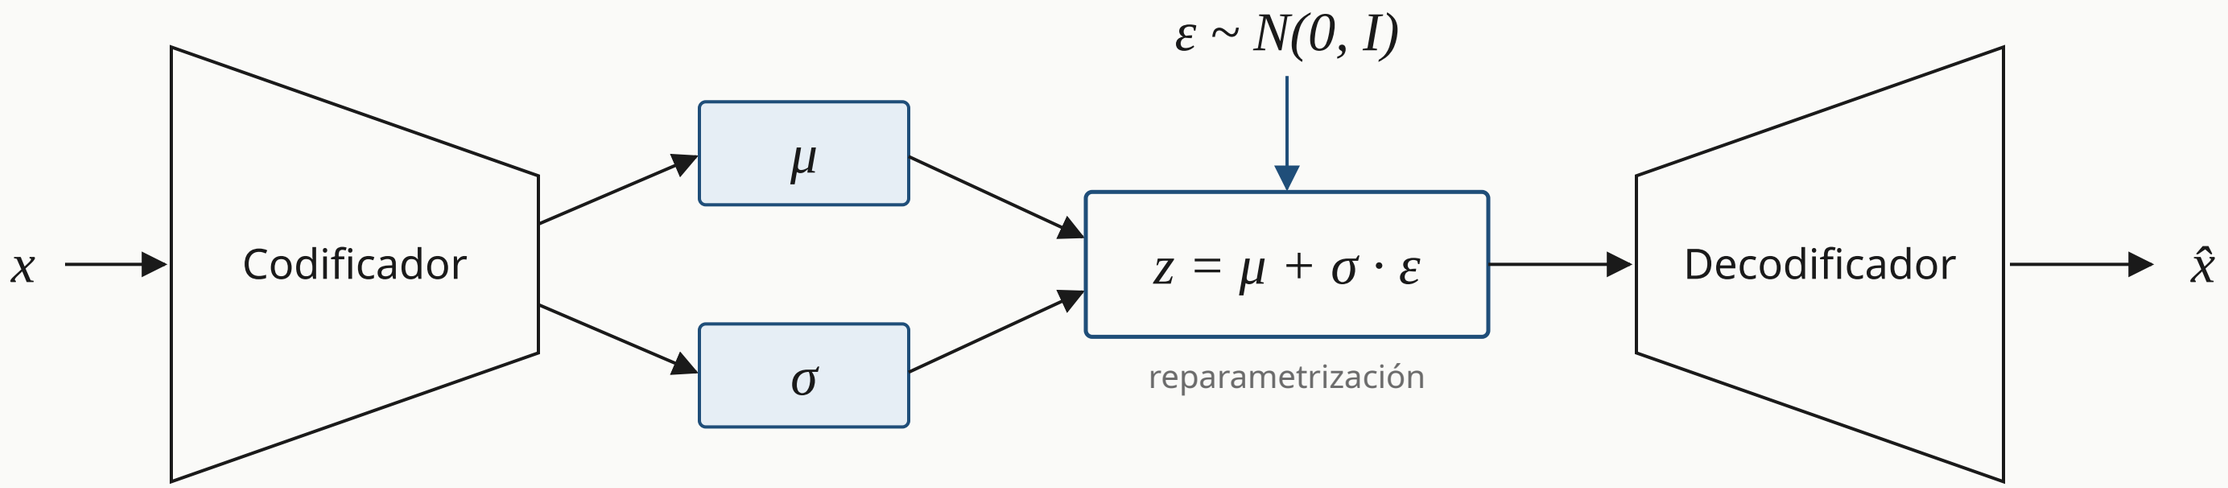
El autocodificador proyecta los datos a un espacio latente y los reconstruye, pero ese espacio latente es discontinuo





$L(\theta, \varphi) = \Sigma_i \, \|x_i - D_\varphi(C_\theta(x_i))\|^2$ Sin restricción sobre la estructura del espacio latente.

El autocodificador variacional codifica cada observación como una distribución, no como un punto



El codificador produce un vector de medias μ y uno de desvíos σ; la reparametrización permite retropropagar a través del muestreo.

Generación: muestrear z de N(0, I) y decodificar.

La pérdida del AV equilibra reconstrucción y regularización del espacio latente

Cota inferior de la evidencia (ELBO)

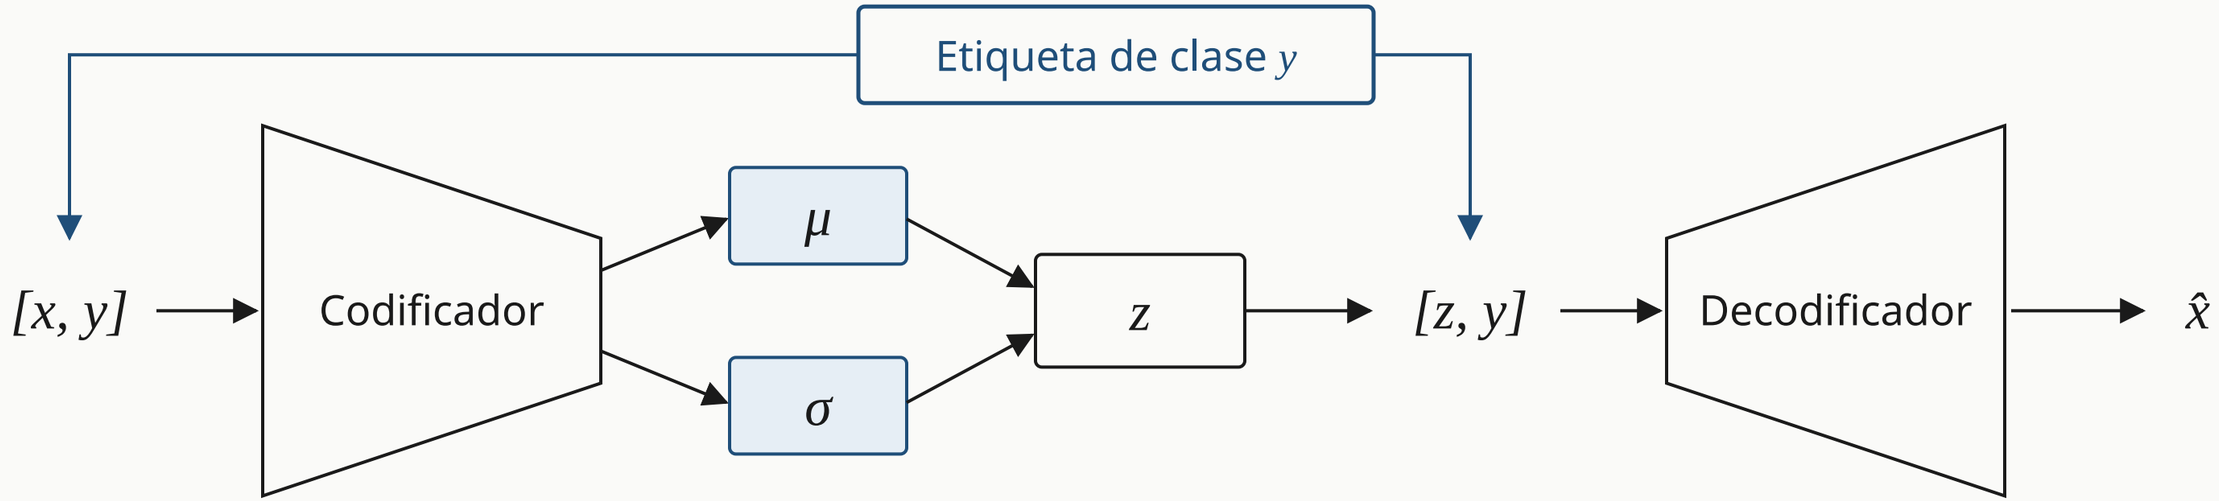
$$\log p_\theta(x) \geq \underbrace{\mathrm{E}_{z \sim q_\varphi(z|x)}\left[\log p_\theta(x|z)\right]}_{\text{Reconstrucción}} - \underbrace{D_{\mathrm{KL}}\left(q_\varphi(z|x) \,\|\, p(z)\right)}_{\text{Regularización}}$$

Reconstrucción
en la práctica, error cuadrático medio

Regularización
divergencia KL respecto de N(0, I)

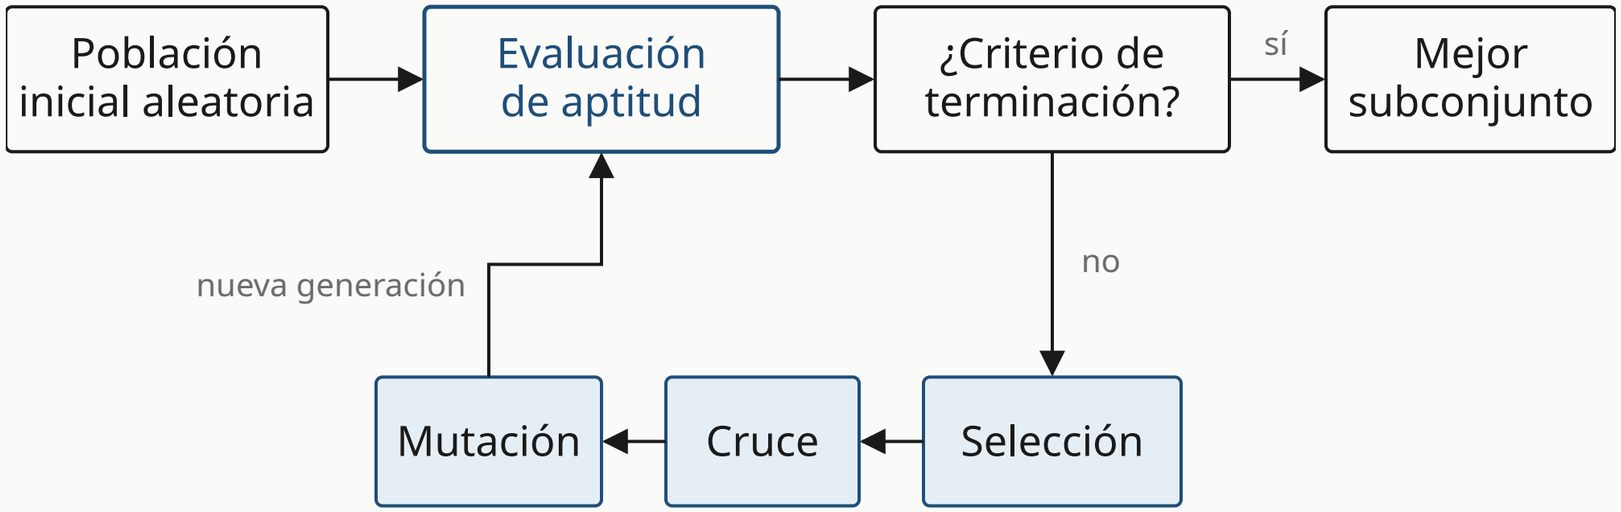
Si la divergencia KL domina la pérdida, el espacio latente queda bien regularizado, pero la reconstrucción se degrada.

El autocodificador variacional condicional incorpora la etiqueta de clase y permite generar muestras por clase en problemas desbalanceados



- La etiqueta de clase se concatena a la entrada del codificador y a la del decodificador.
- Pesos de clase inversos a la frecuencia en la pérdida de reconstrucción.
- Muestreo ponderado por clase en cada mini-lote.

El algoritmo genético evoluciona una población de soluciones codificadas mediante selección, cruce y mutación



Cuatro propiedades (Goldberg)

- Opera sobre una codificación de las soluciones.
- Evalúa una población, no un punto único.
- Usa una función de aptitud, sin derivadas.
- Aplica reglas de transición probabilísticas.

Adecuado para espacios de búsqueda discretos, no diferenciables y multimodales.

En la selección de características, cada cromosoma es una cadena binaria que indica qué variables se incluyen

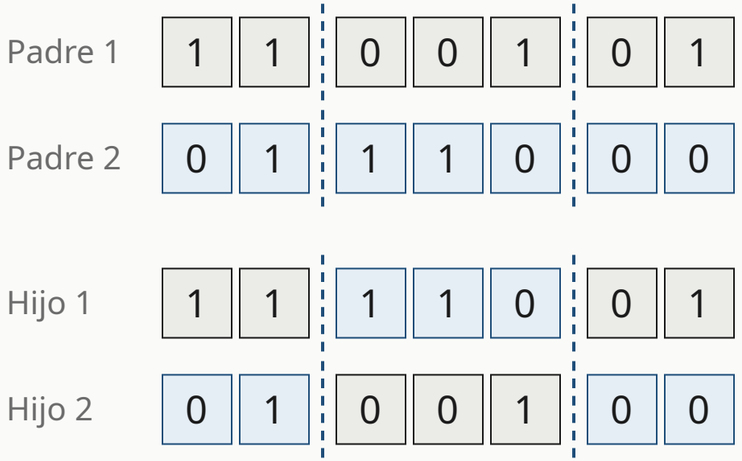
Codificación binaria

	X1	X2	X3	X4	X5	X6	X7
Genotipo	1	1	0	0	1	0	1

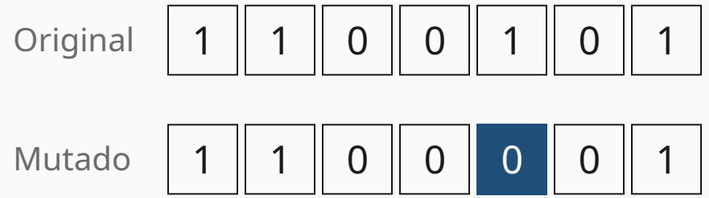
Fenotipo: {X1, X2, X5, X7}

Subconjunto de variables con el que se entrena el clasificador.

Cruce de dos puntos



Mutación por inversión de bits



Cada bit se invierte con una probabilidad fija.

La longitud del cromosoma es igual al número de variables: 7.129 bits en Leukemia, 16.063 en GCM. La proporción de bits activos en la inicialización define el tamaño del subconjunto explorado.

Tres criterios definen la mejora en la selección de características: desempeño predictivo, reducción de variables y estabilidad

Desempeño predictivo	Exactitud del subconjunto encontrado, medida en la partición original de testeo. En los problemas multiclase la aptitud usa exactitud balanceada.
Reducción de variables	Número medio de características seleccionadas en la población final.
Estabilidad	Dispersión de la exactitud y del número de variables entre corridas independientes: desviación estándar y rango intercuartílico.

Los tres criterios no varían conjuntamente; se reportan por separado.

Organización

1 Introducción
motivación, selección de características, estado del arte, propuesta y objetivos

2 Marco teórico
autocodificadores variacionales, algoritmos genéticos, métricas

3 Materiales y métodos
conjuntos de datos, línea base, modelos, diseño experimental

4 Resultados
calidad de los datos sintéticos, resultados globales, análisis por conjunto

5 Conclusiones y trabajos futuros
conclusiones, limitaciones, trabajos futuros

Cinco conjuntos de datos cubren los cuatro problemas: tres de expresión génica y dos del desafío NIPS 2003

Conjunto	Observaciones × características	Clases	Desafío principal
Leukemia	72 × 7.129	2, desbalanceado	Más variables que observaciones; correlación entre genes
Gisette	13.500 × 5.000	2, balanceado	Ruido y redundancia en un espacio de búsqueda grande
Madelon	2.000 × 500	2, balanceado	20 variables con señal y 480 de ruido
GCM	190 × 16.063	14, desbalanceado	Más variables que observaciones; multiclase con desbalance
ALL Leukemia	327 × 12.600	14, desbalanceado	Más variables que observaciones; multiclase. Validación del flujo

Expresión génica: Leukemia (Golub et al., 1999), GCM (Ramaswamy et al., 2001) y ALL Leukemia (Yeoh et al., 2002). Desafío NIPS 2003: Gisette y Madelon.

En todos los experimentos con AV y AG se respetan las particiones originales de entrenamiento y testeo.

Los modelos clásicos sobre el conjunto completo de variables establecen la línea base y caracterizan la dificultad de cada problema

Conjunto	Métrica	Mejor resultado	Rango de la mayoría de los modelos	Lectura
Leukemia	AUC	1,00 (Bagging, Random Forest, SVC)	0,85 a 1,00	Cercano a la saturación
Gisette	AUC	1,00 (Gradient Boosting)	0,92 a 0,99	Cercano a la saturación
Madelon	AUC	0,91 (Bagging)	0,57 a 0,70	Margen de mejora amplio
GCM	Macro-F1	0,71 (SGD); 0,68 (MLP)	0,48 a 0,62	Margen de mejora amplio; clases con F1 nulo

Dieciocho modelos de scikit-learn con búsqueda en grilla, sobre una partición 80/20. Tabla 2.1 de la tesis.

Arquitectura final de AV y AVC: tres capas con normalización por lotes e hiperparámetros ajustados por conjunto

Codificador. Tres capas lineales, cada una con normalización por lotes y ReLU.

Espacio latente. μ y $\log \sigma^2$ mediante dos capas lineales independientes.

Decodificador. Simétrico al codificador. Pérdida: error cuadrático medio + divergencia KL.

Conjunto	Modelo	Neuronas en capas 2 y 3	Dimensión latente	Tasa de aprendizaje	Épocas
Leukemia	AV	346, 178	108	$2{,}7 \cdot 10^{-4}$	2.889
Madelon	AV	835, 308	25	$1{,}6 \cdot 10^{-4}$	1.364
Gisette	AV	3.870, 2.987	18	$9{,}5 \cdot 10^{-4}$	2.739
GCM	AVC	358, 189	35	$6{,}9 \cdot 10^{-4}$	3.613
ALL Leukemia	AVC	434, 176	35	$4{,}0 \cdot 10^{-4}$	949

Optimizador Adam, parada temprana e hiperparámetros por búsqueda en grilla y optimización bayesiana. En multiclase, error de reconstrucción balanceado por clase. Tabla 4.1 de la tesis.

La función de aptitud del AG pondera con igual peso la exactitud y la reducción del número de variables

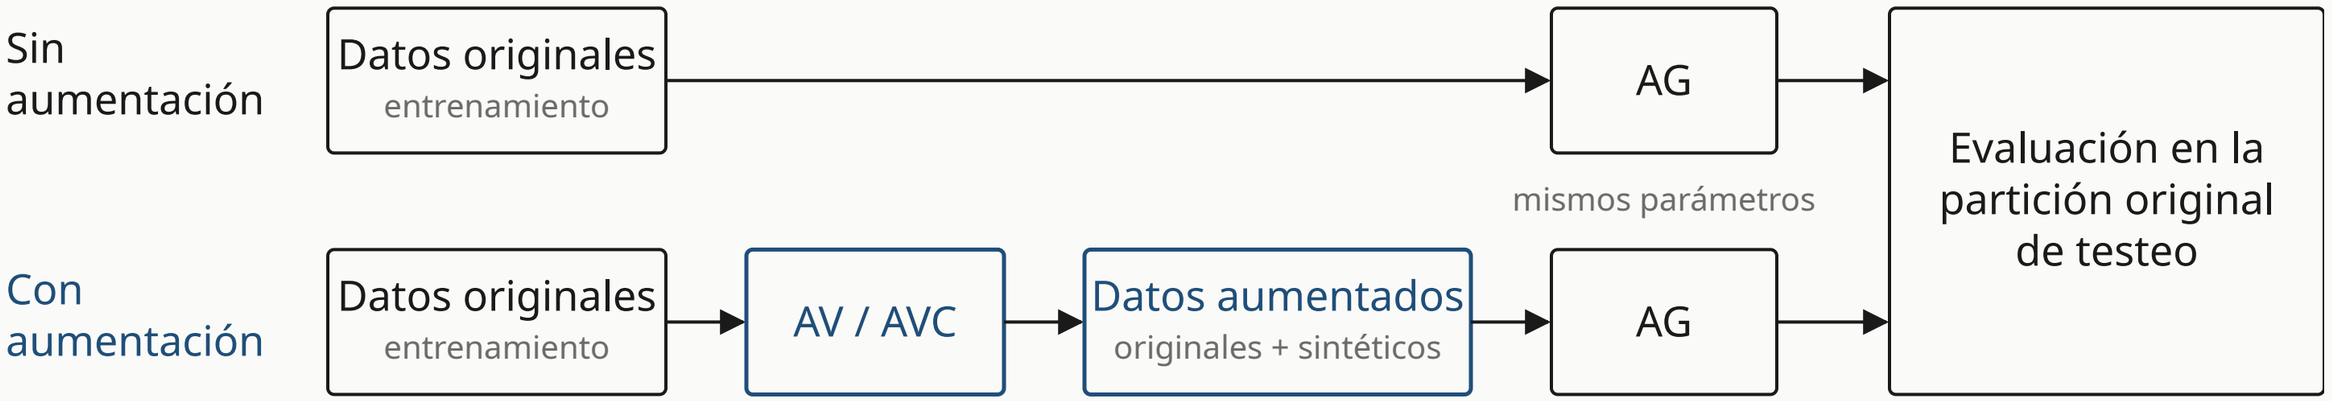
$$f = \alpha \cdot exactitud + (1 - \alpha) \cdot (1 - k / n)$$

α = 0,5 · k: variables seleccionadas · n: variables totales

- Población de individuos binarios.
- Selección por torneo.
- Cruce de dos puntos, probabilidad 0,75.
- Mutación por inversión de bits; probabilidad ajustada por conjunto, entre 0,0002 y 0,1.
- Entre 15 y 30 generaciones.
- Evaluador: perceptrón multicapa (MLP). Biblioteca DEAP.

Por diseño, el AG resigna parte de la exactitud a cambio de una menor dimensionalidad.

El diseño experimental compara el mismo AG con y sin aumentación, evaluado siempre en la partición original de testeo



- Cada corrida completa del AG es una observación: exactitud media de la población final.
- Comparación de distribuciones entre grupos: gráficos de cajas, test t de Welch y test de Mann-Whitney.

Para los problemas multiclase se diseñó un flujo en tres etapas: selección, generación y selección

1. Selección

AG sobre el espacio completo de variables.

Salida: las características más frecuentes en los cromosomas finales.

→

2. Generación

AVC entrenado en el subespacio seleccionado.

Salida: muestras sintéticas balanceadas por clase.

→

3. Selección

AG final sobre datos originales y sintéticos.

Salida: subconjunto de características.

Conjunto	Subespacio de la etapa 1	Muestras sintéticas de la etapa 2
GCM	1.600 características, obtenidas de 590 cromosomas	3.000, balanceadas por clase
ALL Leukemia	Características obtenidas de 3 corridas del AG	1.000

Ejecución en la nube: 8 vCPU y 30 GB de memoria.

Organización

1 Introducción
motivación, selección de características, estado del arte, propuesta y objetivos

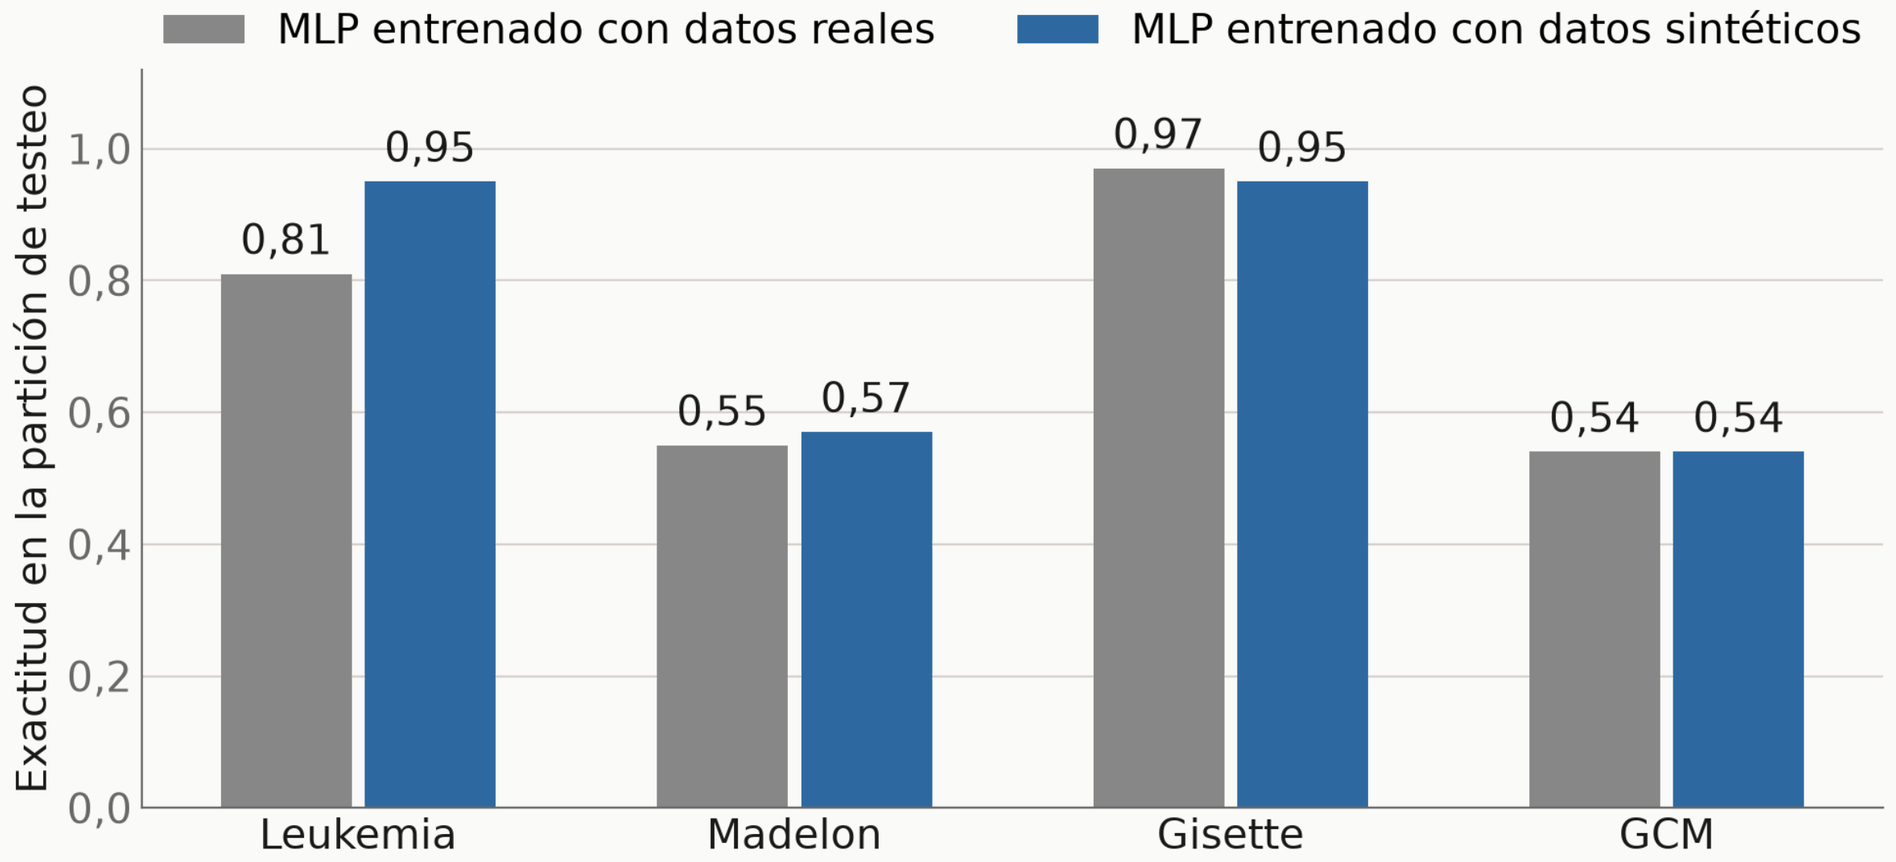
2 Marco teórico
autocodificadores variacionales, algoritmos genéticos, métricas

3 Materiales y métodos
conjuntos de datos, línea base, modelos, diseño experimental

4 Resultados
calidad de los datos sintéticos, resultados globales, análisis por conjunto

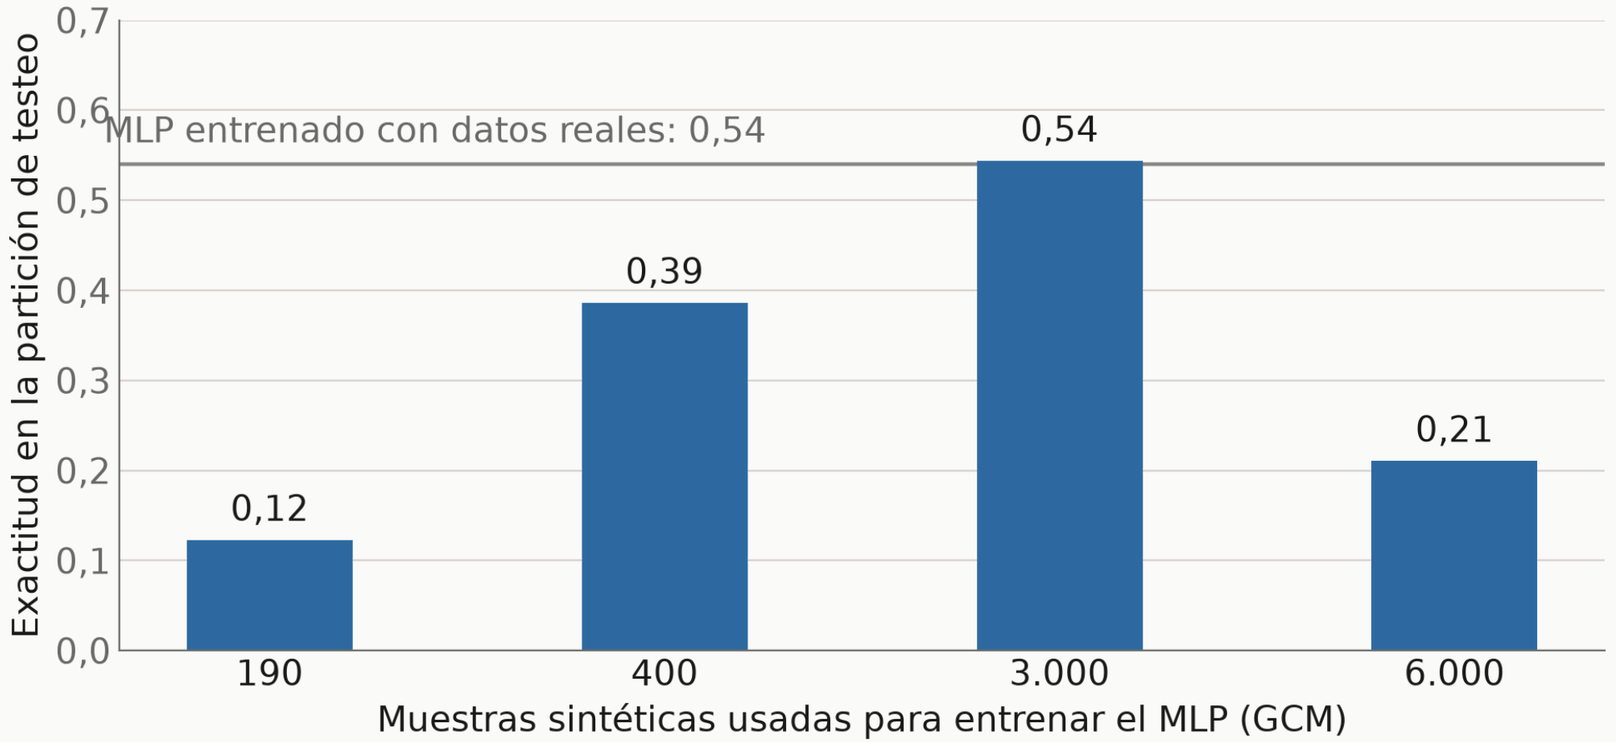
5 Conclusiones y trabajos futuros
conclusiones, limitaciones, trabajos futuros

Un MLP entrenado únicamente con datos sintéticos alcanza la exactitud del entrenado con datos reales en tres de los cuatro conjuntos



Ambos modelos se evalúan en la partición original de testeo. Figura 3.4 de la tesis.

La cantidad de muestras sintéticas presenta un umbral: en GCM, superarlo degrada la exactitud



Con 3.000 muestras balanceadas (214 por clase) se iguala al MLP entrenado con datos reales; con 6.000, la exactitud se degrada.

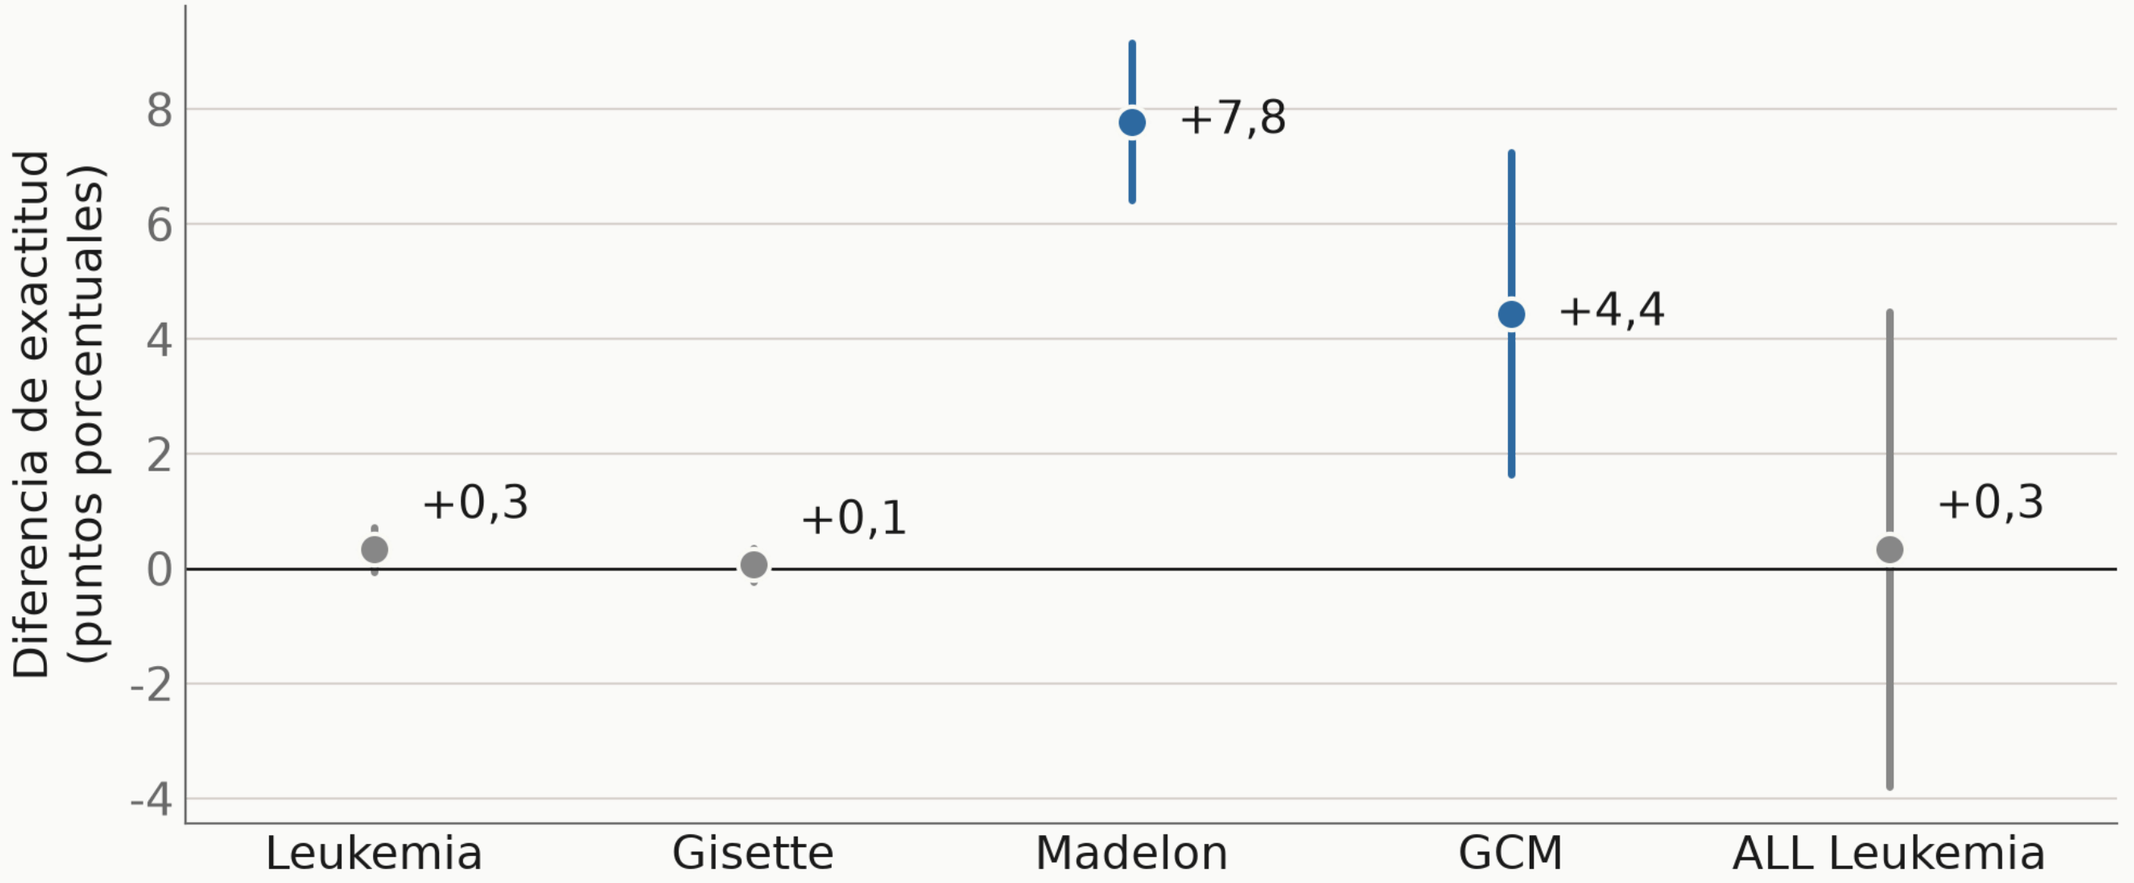
Un espacio latente de 35 dimensiones superó a las configuraciones de más de 50. Figura 3.5 de la tesis.

Resultados globales: la aumentación mejoró significativamente la exactitud en dos de los cinco conjuntos y no la modificó en los otros tres

Conjunto	Corridas con / sin	Exactitud sin aumentación	Exactitud con aumentación	Diferencia (puntos porcentuales)	p	Lectura
Leukemia	90 / 90	0,989	0,992	+0,3	0,09	Saturado, sin cambio
Gisette	13 / 12	0,959	0,960	+0,1	0,63	Saturado, sin cambio
Madelon	30 / 49	0,750	0,828	**+7,8**	< 0,001	Mejora significativa
GCM, segunda etapa	9 / 10	0,497	0,541	**+4,4**	0,005	Mejora significativa
ALL Leukemia	18 / 18	0,669	0,672	+0,3	0,87	Sin cambio

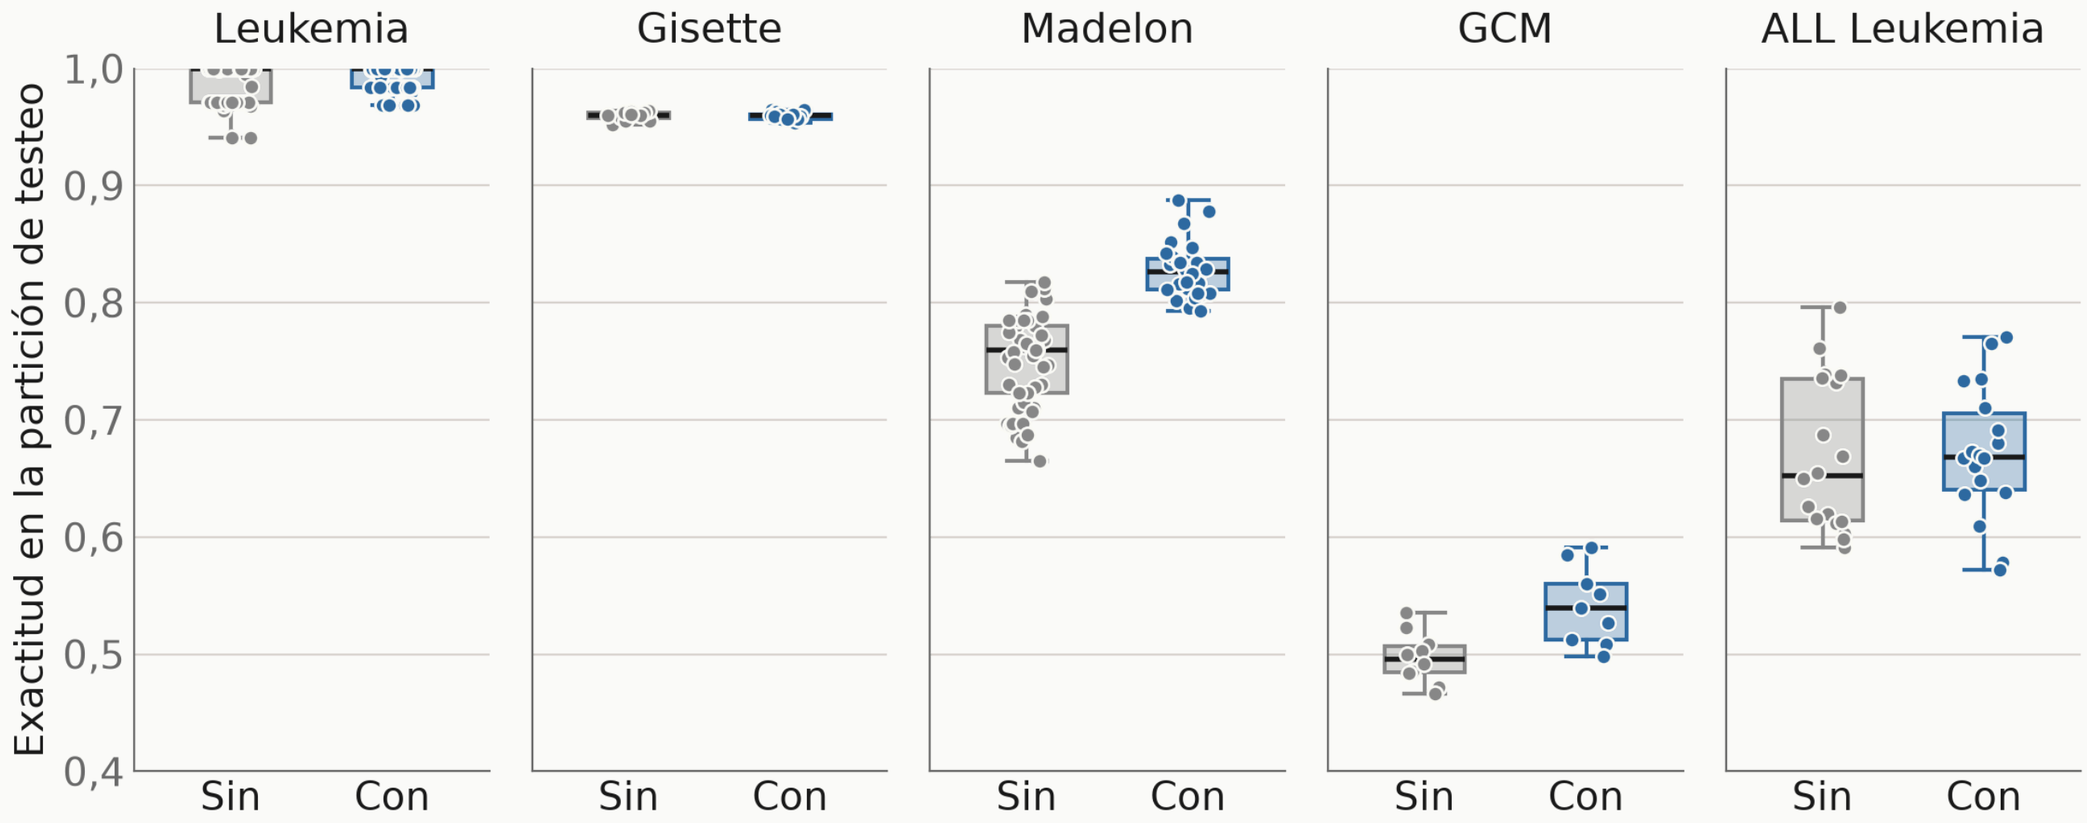
Test t de Welch con las corridas del AG como unidad de observación. El test de Mann-Whitney conduce a la misma conclusión en todos los casos.

Los intervalos de confianza del 95% excluyen el cero únicamente en Madelon y GCM



Diferencia de medias (con aumentación menos sin aumentación) e intervalo de confianza del 95%. Donde el intervalo incluye el cero no hay evidencia de efecto.

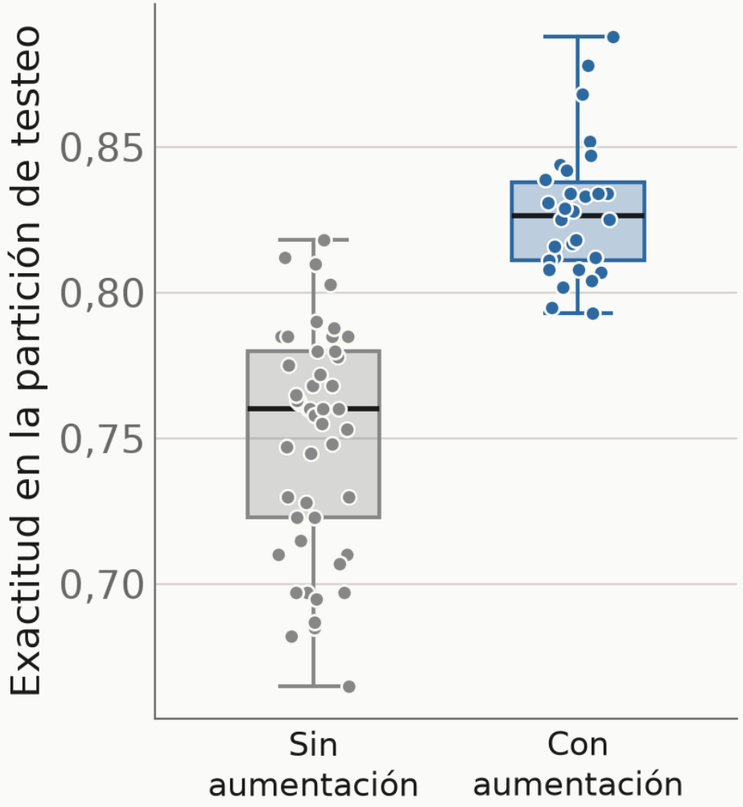
Con escala común, la diferencia solo es apreciable en los conjuntos con margen de mejora

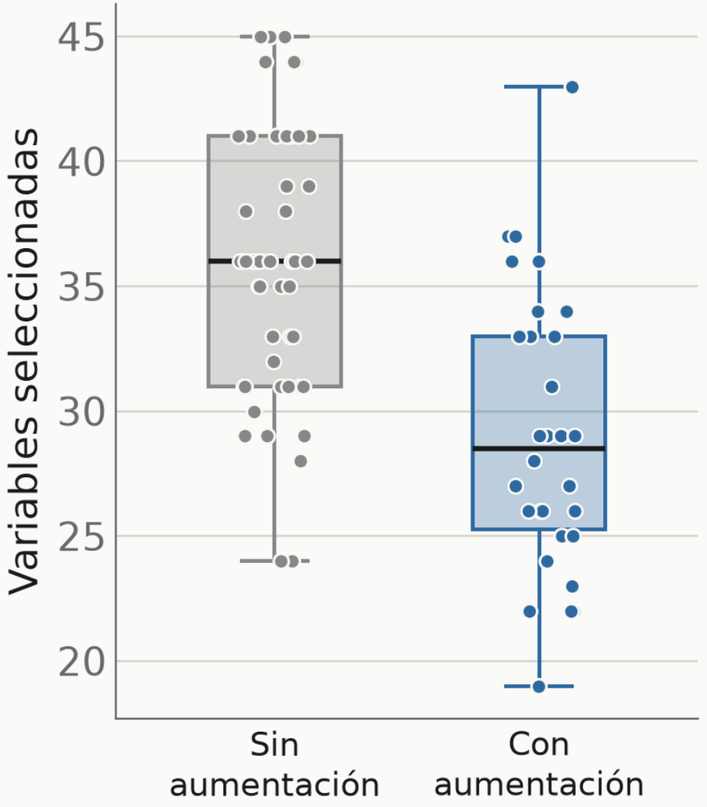


Problema saturado: sin cambio.

Margen de mejora y reconstrucción adecuada: mejora.

Madelon: la aumentación incrementa la exactitud en 7,8 puntos porcentuales y reduce el número de variables seleccionadas





+7,8

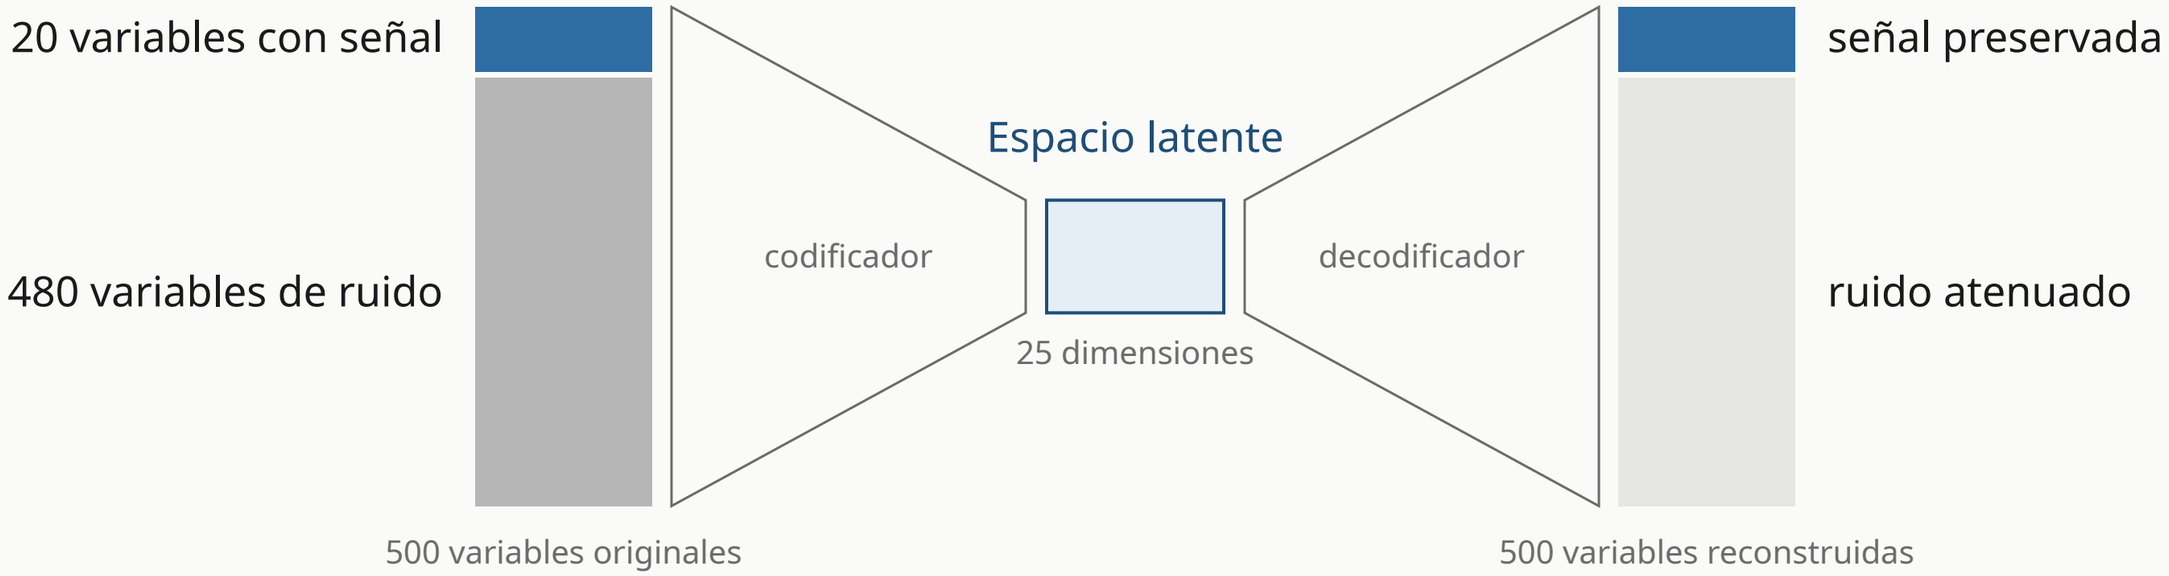
puntos porcentuales de exactitud
0,750 → 0,828 ($p < 0,001$)

29

variables seleccionadas en promedio,
frente a 36 sin aumentación

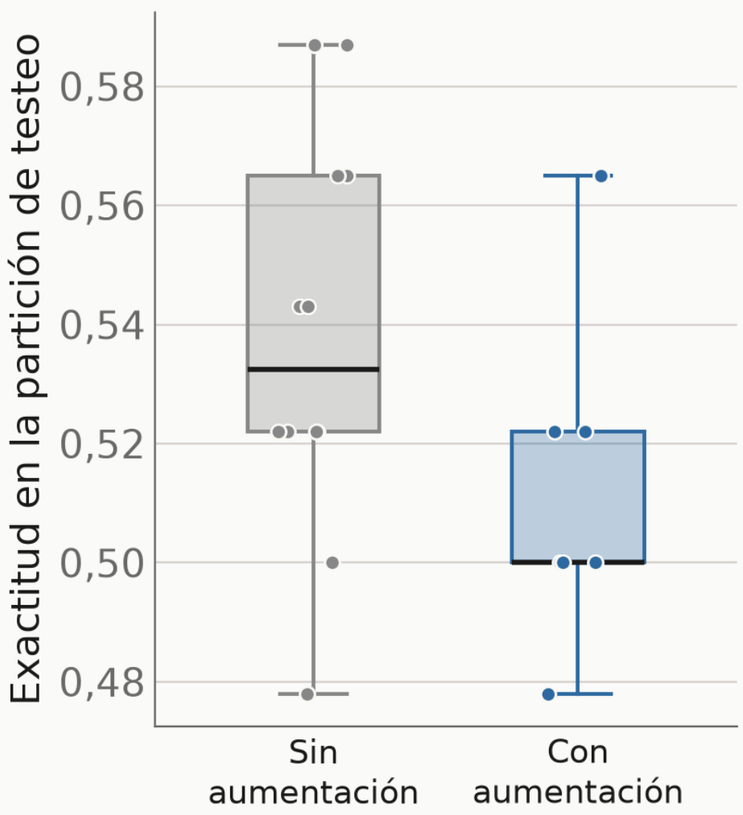
30 corridas con aumentación y 49 sin aumentación. La desviación estándar de la exactitud también disminuye: 0,023 frente a 0,038.

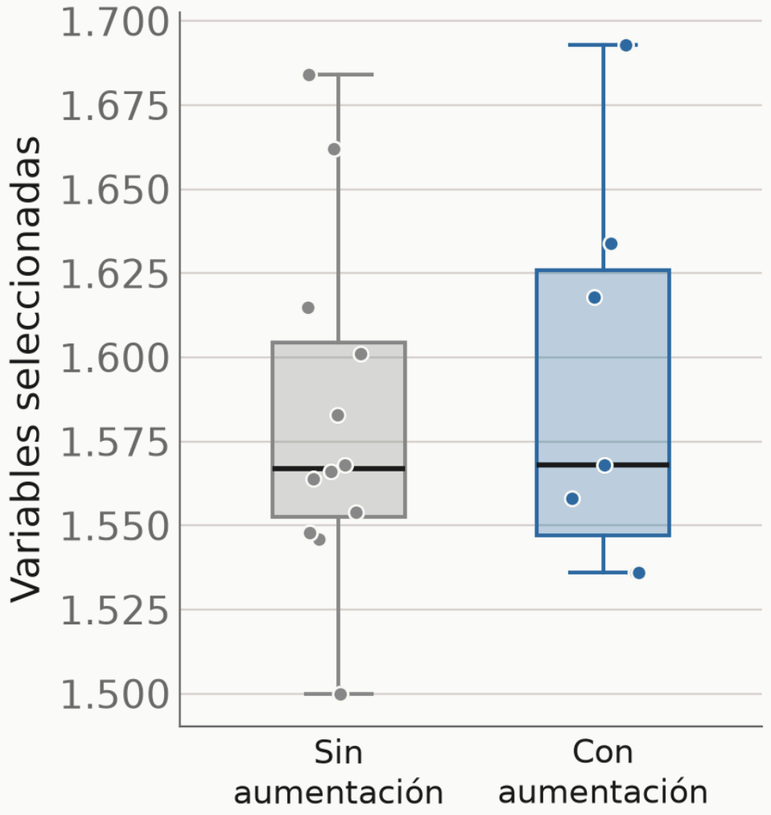
Interpretación del caso Madelon: un espacio latente compacto preserva las 20 variables informativas y atenúa las 480 de ruido



Los datos sintéticos realzan la señal que el AG debe encontrar. Esquema ilustrativo de la interpretación propuesta en la tesis; no es un resultado medido.

GCM, primera etapa: con el AVC entrenado sobre las 16.063 variables, la aumentación no mejoró la exactitud





0,538

exactitud sin aumentación

0,512

exactitud con aumentación

1.400 muestras sintéticas (100 por clase) más 133 originales; cromosomas de aproximadamente 1.600 genes; 20 generaciones. Figura 4.10 de la tesis.

Diagnóstico: el clasificador ajusta por completo la distribución sintética, pero no generaliza a la distribución real

100%

exactitud en la partición sintética de testeo

50%

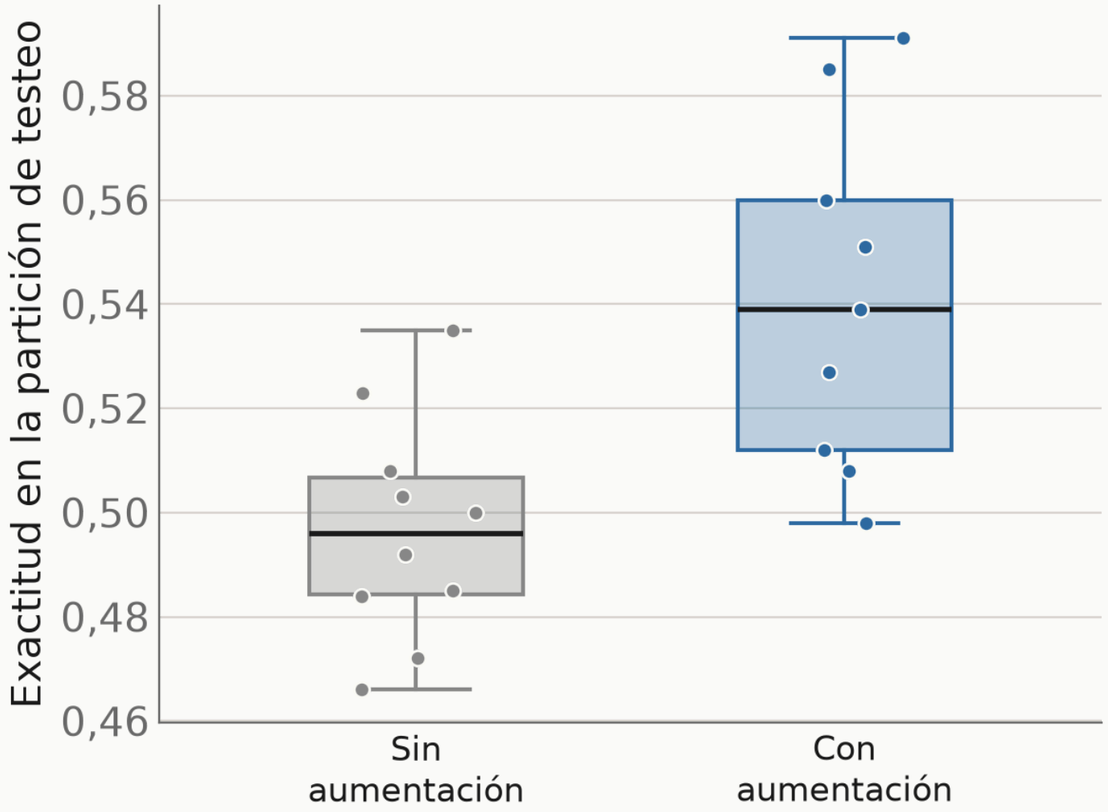
exactitud en la partición real de testeo

MLP entrenado con 3.000 muestras sintéticas. Tabla 4.4 de la tesis.

La distribución sintética es internamente consistente y de menor complejidad que la real: permite igualar al MLP entrenado con datos reales, no superarlo ni guiar mejor al AG.

Explicación plausible: colapso de la distribución posterior. La divergencia KL domina la pérdida y la reconstrucción deja de representar los datos reales.

GCM, segunda etapa: con el flujo selección-generación-selección, la aumentación incrementa la exactitud en 4,4 puntos porcentuales



+4,4

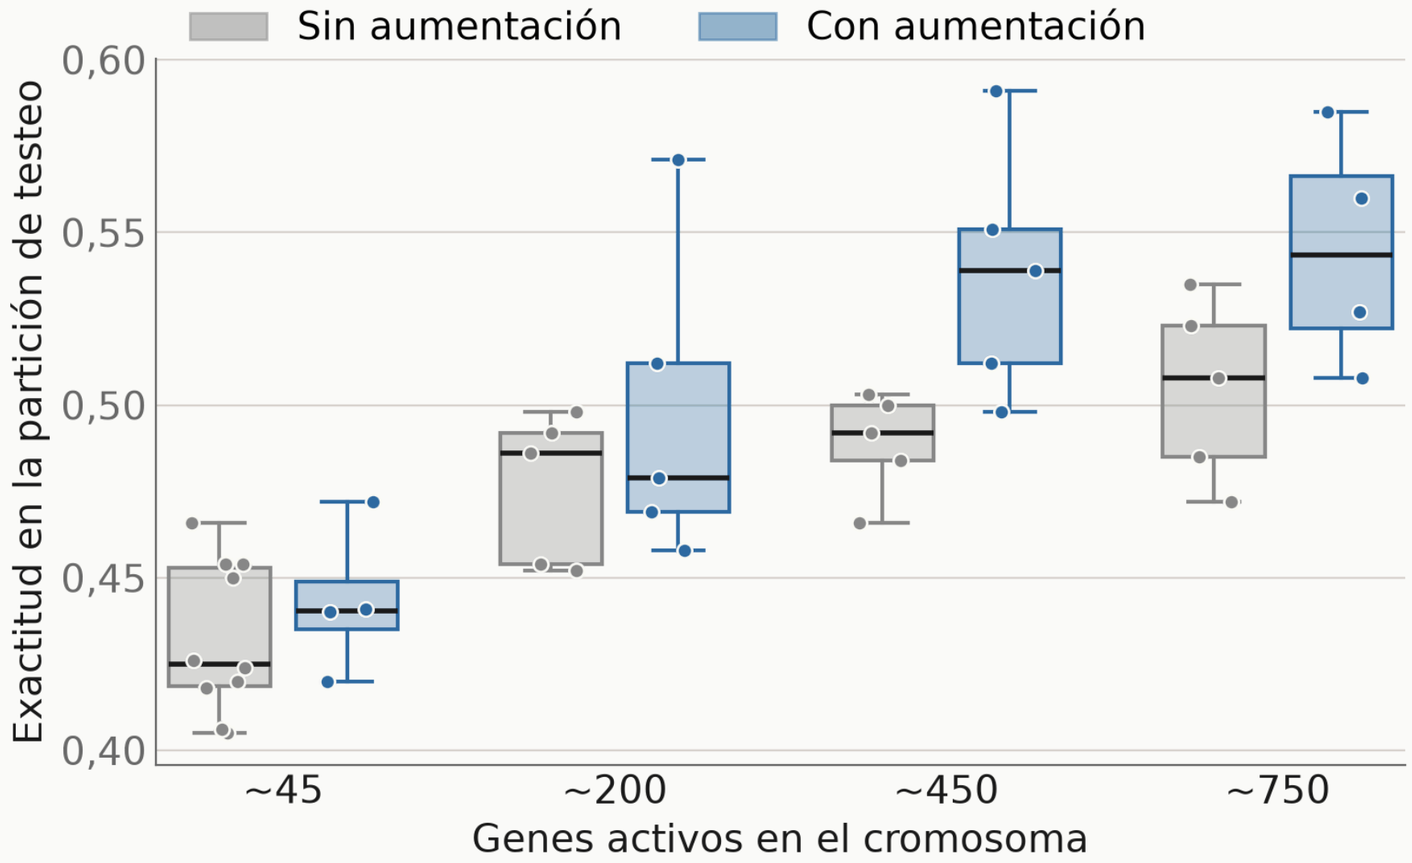
puntos porcentuales de exactitud
0,497 → 0,541 (p = 0,005)

9 corridas con aumentación y 10 sin aumentación, con cromosomas de aproximadamente 450 y 750 genes.

Número de variables sin cambio dentro de cada tamaño de cromosoma: 454 frente a 462, y 785 frente a 781.

AVC entrenado sobre las 1.600 características más frecuentes; 3.000 muestras sintéticas balanceadas por clase; 15 generaciones. Figura 4.11 de la tesis.

GCM con reducción progresiva del cromosoma: la exactitud se mantiene hasta ~45 genes y la media con aumentación es superior en los cuatro tamaños

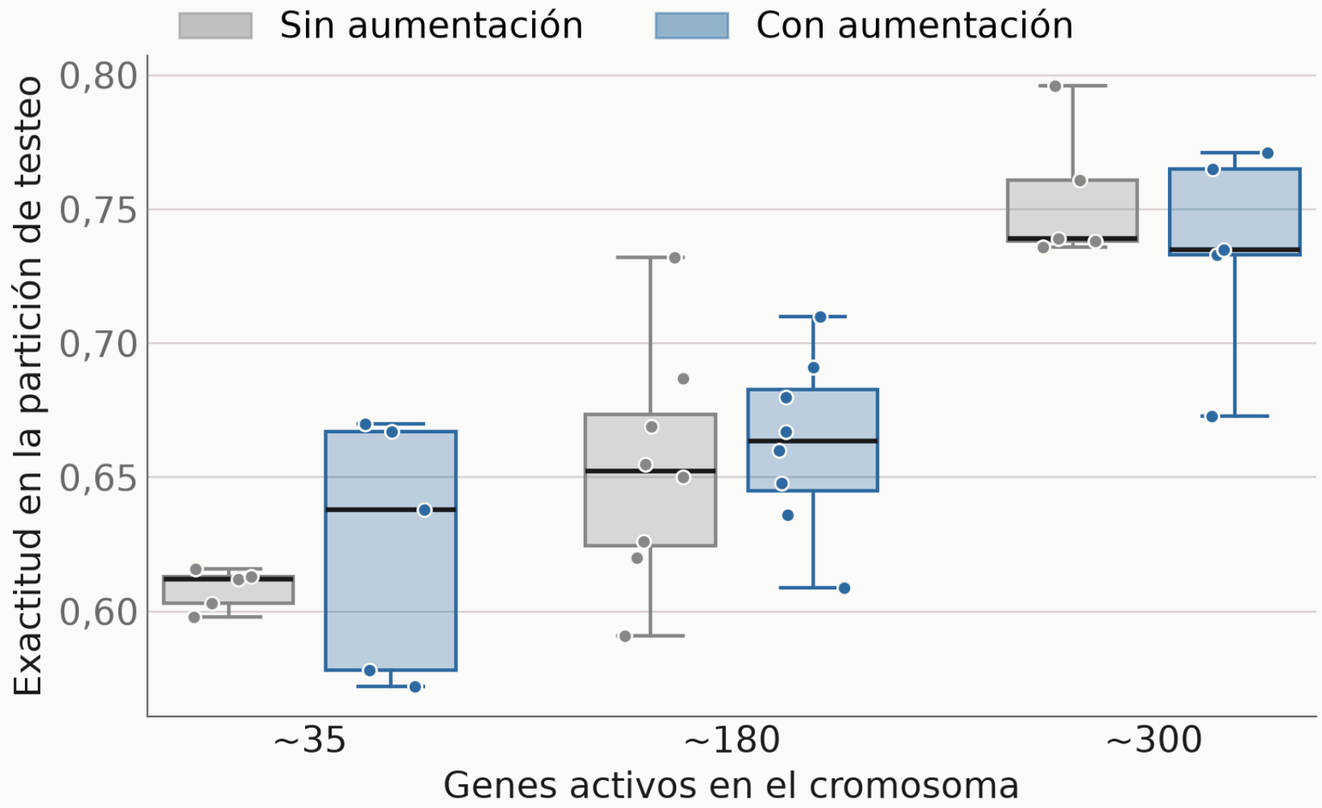


Genes activos	Corridas con / sin	Sin aum.	Con aum.	p
~45	4 / 10	0,432	0,443	0,43
~200	5 / 5	0,476	0,498	0,38
~450	5 / 5	0,489	0,538	0,035
~750	4 / 5	0,505	0,545	0,10

Exactitud media por grupo. Solo el tamaño ~450 alcanza significación estadística por sí solo.

Figura 4.12 de la tesis, redibujada con los mismos datos.

ALL Leukemia valida el flujo en un segundo problema multiclase: tendencia favorable, sin significación estadística

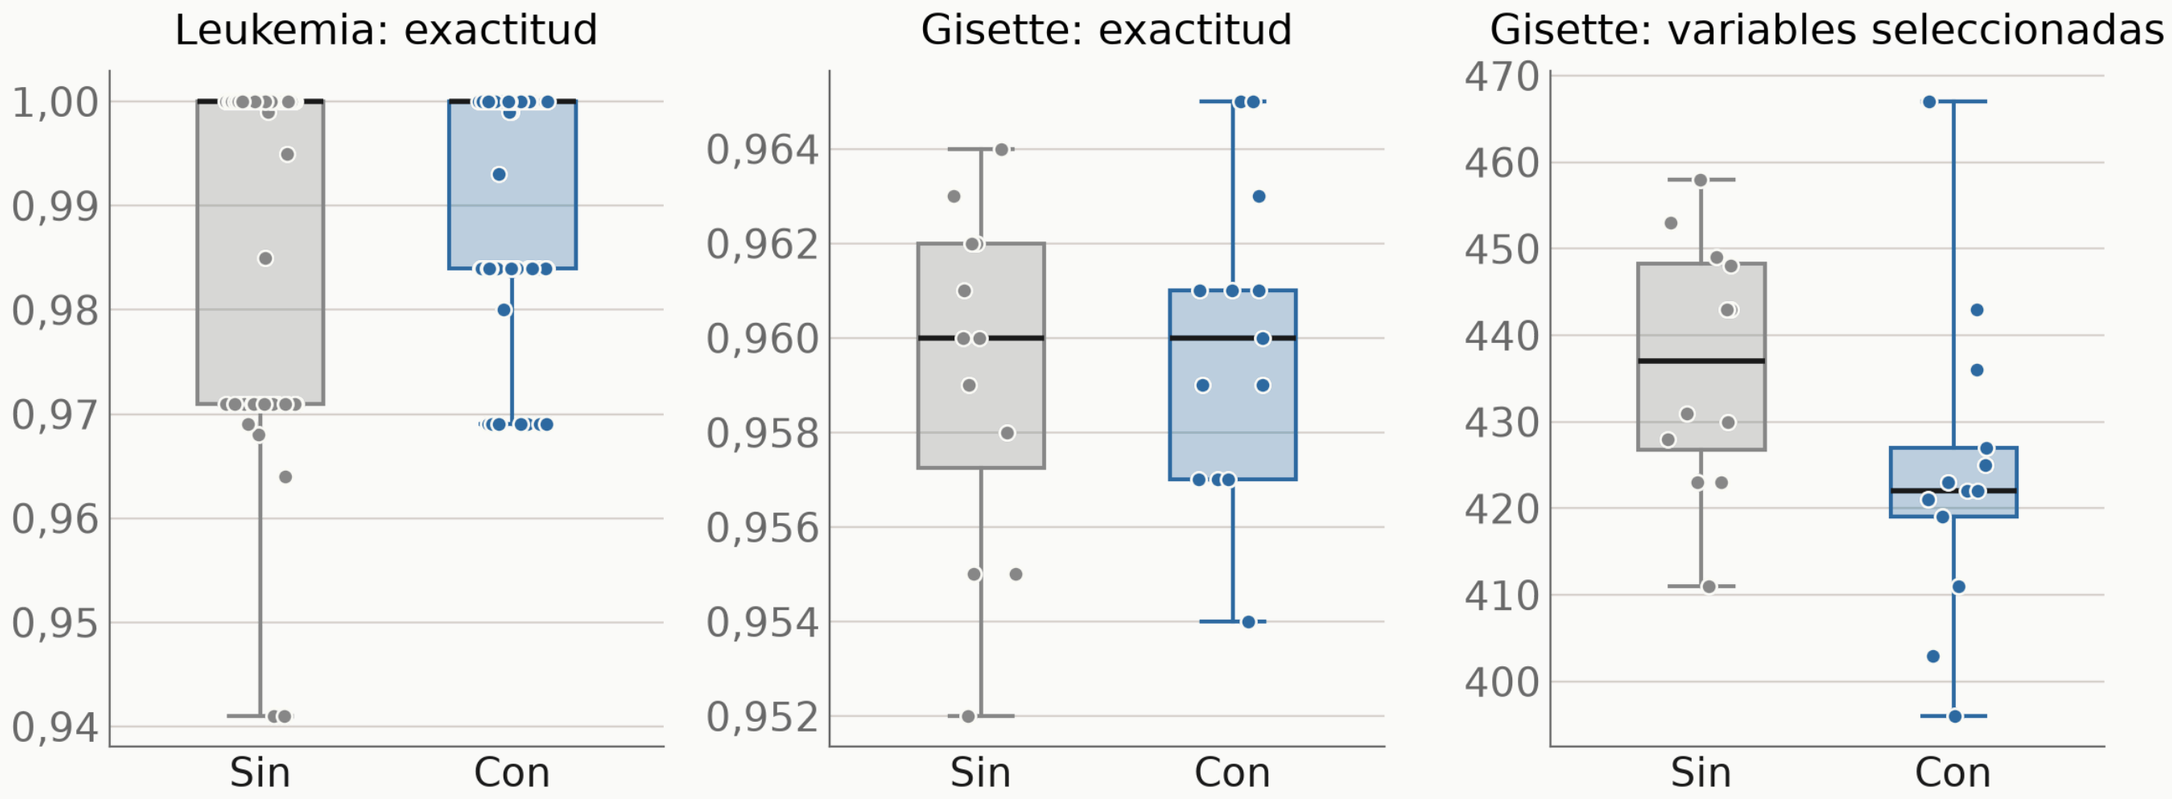


Genes activos	Corridas con / sin	Sin aum.	Con aum.	p
~35	5 / 5	0,608	0,625	0,48
~180	8 / 8	0,654	0,663	0,65
~300	5 / 5	0,754	0,735	0,40

Exactitud media por grupo. Ninguna diferencia es estadísticamente significativa.

Mismo flujo que en GCM: AVC sobre el subespacio seleccionado, 1.000 muestras sintéticas, 15 generaciones. Figura 4.13 de la tesis, redibujada con los mismos datos.

En los conjuntos saturados la aumentación no modifica la exactitud, pero reduce la dispersión entre corridas



Leukemia. Desviación estándar de la exactitud: 0,011 con aumentación frente a 0,016 sin aumentación.

Gisette. 424 variables seleccionadas frente a 437; rango intercuartílico de 8 frente a 21.

Evaluación por criterio: desempeño predictivo, reducción de variables y estabilidad en cada conjunto

Conjunto	Desempeño predictivo	Reducción de variables	Estabilidad de la exactitud
Leukemia	Sin diferencia (p = 0,09)	Igual (259 y 259)	**Mejora** (0,011 frente a 0,016)
Gisette	Sin diferencia (p = 0,63)	**Mejora** (424 frente a 437)	**Mejora leve** (0,003 frente a 0,004)
Madelon	**Mejora** (p < 0,001)	**Mejora** (29 frente a 36)	**Mejora** (0,023 frente a 0,038)
GCM, segunda etapa	**Mejora** (p = 0,005)	Igual (454 y 462; 785 y 781)	Empeora (0,033 frente a 0,022)
ALL Leukemia	Sin diferencia (p = 0,87)	Igual (174 y 173)	**Mejora leve** (0,056 frente a 0,065)

En cada celda, el valor con aumentación precede al valor sin aumentación. Estabilidad: desviación estándar de la exactitud entre corridas.

Síntesis: el efecto de la aumentación está condicionado por el margen de mejora y la calidad de la reconstrucción

Mejora	La aumentación mejora la exactitud donde existe margen de mejora y el AV reconstruye adecuadamente: Madelon y GCM en segunda etapa.
Sin cambio	No modifica la exactitud en problemas saturados (Leukemia, Gisette); aporta estabilidad.
Condición	En problemas multiclase desbalanceados requiere generar sobre un subespacio seleccionado y calibrar la cantidad de muestras.

Organización

1 Introducción
motivación, selección de características, estado del arte, propuesta y objetivos

2 Marco teórico
autocodificadores variacionales, algoritmos genéticos, métricas

3 Materiales y métodos
conjuntos de datos, línea base, modelos, diseño experimental

4 Resultados
calidad de los datos sintéticos, resultados globales, análisis por conjunto

5 Conclusiones y trabajos futuros
conclusiones, limitaciones, trabajos futuros

Conclusiones

1. Los datos sintéticos generados por un AV o AVC adecuadamente configurado son aptos para el entrenamiento: un MLP entrenado únicamente con sintéticos alcanza la exactitud del entrenado con reales en Leukemia, Madelon y GCM.
2. La aumentación mejora la selección con AG cuando el problema tiene margen de mejora y el AV reconstruye adecuadamente: +7,8 puntos porcentuales en Madelon y +4,4 en GCM, ambos significativos.
3. En problemas saturados no modifica la exactitud; reduce la dispersión y, en algunos casos, el tamaño del subconjunto.
4. En problemas multiclase desbalanceados, el flujo selección-generación-selección es la condición para que la aumentación resulte útil; aplicar el AVC sobre el espacio completo la perjudicó.

Limitaciones

1. Cinco conjuntos de datos, dos de ellos artificiales; el efecto depende de la dificultad del problema.
2. Número reducido de corridas en GCM y ALL Leukemia (5 a 10 por configuración) y particiones de testeo pequeñas.
3. El efecto depende de la calidad del AV: con una reconstrucción deficiente, la aumentación perjudica el resultado.
4. Existe un umbral de muestras sintéticas más allá del cual el resultado se degrada.
5. Un único clasificador en la función de aptitud (MLP) e hiperparámetros ajustados por conjunto, no transferibles sin reajuste.

Trabajos futuros

1. **Función de pérdida del AV.** Reponderar reconstrucción y divergencia KL; inferencia variacional recocida; AV jerárquicos para datos como GCM.
2. **Integración AV-AG.** Selección dinámica en varias etapas y optimización conjunta de ambos modelos.
3. **Encadenamientos y ensambles** de AV y AG para reducir la varianza.
4. **Comparación con SMOTE** y otros generadores dentro del mismo flujo con AG.

Tesis de Maestría en Minería de Datos

Aumentación de datos mediante autoencoders variacionales y su impacto en estrategias de selección de características basadas en algoritmos genéticos

Muchas gracias

Claudio Sebastian Castillo

Director: Dr. Matías Gerard · Codirector: Dr. Leandro Vignolo

Código: github.com/castillosebastian/ealab

Comparación con el MLP sobre todas las variables: el flujo AV+AG iguala o supera su exactitud con entre el 0,6% y el 10% de las características

Conjunto	MLP, todas las variables (capítulo 3)	AG sin aumentación	AG con aumentación	Variables usadas por el AG
Leukemia	0,81	0,989	0,992	30 a 680 de 7.129
Gisette	0,97	0,959	0,960	437 y 424 de 5.000
Madelon	0,55	0,750	0,828	36 y 29 de 500
GCM	0,54	0,497	0,541	450 a 780 de 16.063
ALL Leukemia	sin medición	0,669	0,672	35 a 300 de 12.600

Referencias externas. GCM: 78% con SVM uno contra todos sobre los 16.063 genes (Ramaswamy et al., 2001). Madelon: error balanceado cercano a 0,07 en los mejores resultados del desafío NIPS 2003. Leukemia: predictor de 50 genes (Golub et al., 1999).

La función de aptitud pondera la reducción de variables con peso 0,5: el AG resigna exactitud por diseño.

Fundamento de la elección de autocodificadores variacionales frente a SMOTE

Blagus y Lusa, 2013	SMOTE no aporta beneficio en alta dimensionalidad con pocas muestras, el escenario de Leukemia, GCM y ALL Leukemia.
Fajardo et al., 2021	El AV condicional supera al sobremuestreo aleatorio, a SMOTE y a las GAN en MNIST desbalanceado.
Ai et al., 2023	Los AV guiados superan a otros métodos de sobremuestreo en datos tabulares e imágenes.

SMOTE rebalancea clases; la tesis aplica la aumentación también a problemas balanceados. La comparación con SMOTE dentro del mismo flujo no se realizó y queda como trabajo futuro.

Significación en GCM con las corridas reales como n

Comparación	Corridas con / sin	Diferencia (puntos porcentuales)	IC 95%	Welch, p	Mann-Whitney, p
Cromosomas de ~450 y ~750 genes	9 / 10	+4,4	1,6 a 7,3	0,005	0,005
Toda la segunda etapa	18 / 25	+4,0	1,1 a 7,0	0,008	0,011

La unidad de observación es la corrida completa del AG.

El cálculo original de la tesis usó como tamaño muestral la cantidad de observaciones de los conjuntos (3.133 y 133). Recalculada con las corridas, la diferencia se mantiene significativa.

Línea base completa: Tabla 2.1

Modelo	Leukemia (AUC)	Madelon (AUC)	Gisette (AUC)	GCM (macro-F1)
Modelos lineales				
LDA	0,85	0,60	0,96	—
QDA	0,50	0,66	0,70	—
Ridge	0,99	0,60	0,97	—
SGD	0,98	0,64	0,99	**0,71**
Árboles				
AdaBoost	0,91	0,84	0,99	—
Bagging	**1,00**	**0,91**	—	—
Árbol de decisión (DTC)	0,72	0,64	0,92	0,53
Árbol extra (ETC)	0,54	0,57	0,94	0,48
Extra Trees (ensamble)	**1,00**	0,71	0,99	0,57
Gradient Boosting	0,99	0,82	**1,00**	0,58
Random Forest	**1,00**	0,78	0,99	0,62
Máquinas de vectores de soporte				
LSVC	0,99	0,62	0,99	0,62
NuSVC	**1,00**	0,61	0,99	0,58
SVC	**1,00**	0,61	0,99	0,58
Naive Bayes				
Bernoulli (BNB)	0,89	0,63	0,94	—
Gaussiano (GNB)	0,91	0,65	0,85	—
Vecinos más cercanos				
KNN	0,86	0,65	0,99	—
Redes neuronales				
MLP	0,96	0,58	0,99	0,68

En azul, el mejor resultado de cada conjunto. Un guion indica que el modelo no se evaluó en ese conjunto. Tabla 2.1 de la tesis.

Resultados por clase del MLP con datos reales y sintéticos

Leukemia

Entrenamiento	Clase	Precisión	Recall	F1
Datos reales	0	0,76	1,00	0,87
	1	1,00	0,56	0,71
Datos sintéticos	0	0,93	1,00	0,96
	1	1,00	0,89	0,94

Exactitud: 0,81 con datos reales y 0,95 con datos sintéticos. Tabla 3.1 de la tesis.

GCM

		MLP con datos reales			MLP con datos sintéticos		
Clase	Soporte	Precisión	Recall	F1	Precisión	Recall	F1
0	4	0,14	0,25	0,18	1,00	0,25	0,40
1	1	0,00	0,00	0,00	0,00	0,00	0,00
2	3	1,00	1,00	1,00	1,00	0,67	0,80
3	6	1,00	0,33	0,50	1,00	0,17	0,29
4	8	0,89	1,00	0,94	1,00	1,00	1,00
5	3	0,40	0,67	0,50	0,43	1,00	0,60
6	5	0,80	0,80	0,80	1,00	0,80	0,89
7	4	0,50	0,75	0,60	0,10	0,25	0,14
8	4	0,33	0,25	0,29	0,67	0,50	0,57
9	3	0,25	0,67	0,36	0,50	0,33	0,40
10	4	1,00	0,25	0,40	0,00	0,00	0,00
11	3	1,00	0,67	0,80	1,00	0,67	0,80
12	4	1,00	0,25	0,40	1,00	0,75	0,86
13	5	1,00	0,20	0,33	0,21	0,60	0,32
Promedio macro	57	0,67	0,51	0,51	0,64	0,50	0,50

Exactitud: 0,54 en ambos casos. Tabla 3.4 de la tesis.